

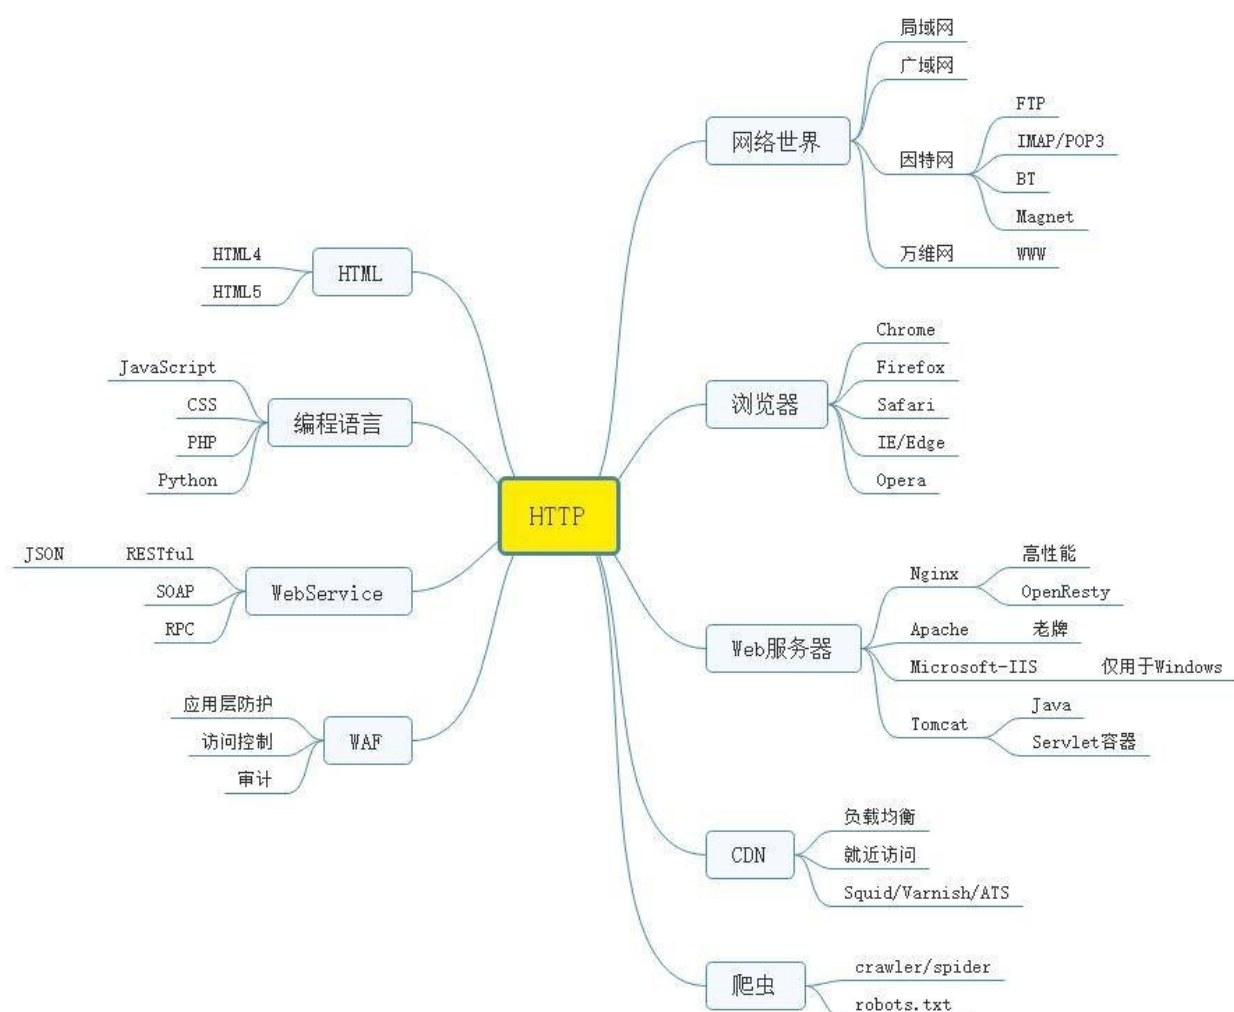
03-HTTP世界全览（上）：与HTTP相关的各种概念

在上一讲的末尾，我画了一张图，里面是与HTTP关联的各种技术和知识点，也可以说是这个专栏的总索引，不知道你有没有认真看过呢？

那张图左边的部分是与HTTP有关系的各种协议，比较偏向于理论；而右边的部分是与HTTP有关系的各种应用技术，偏向于实际应用。

我希望借助这张图帮你澄清与HTTP相关的各种概念和角色，让你在实际工作中清楚它们在链路中的位置和作用，知道发起一个HTTP请求会有哪些角色参与，会如何影响请求的处理，做到“手中有粮，心中不慌”。

因为那张图比较大，所以我会把左右两部分拆开来分别讲，今天先讲右边的部分，也就是与HTTP相关的各种应用，着重介绍互联网、浏览器、Web服务器等常见且重要的概念。



为了方便你查看，我又把这部分重新画了一下，比那张大图小了一些，更容易地阅读，你可以[点击查看](#)。

暖场词就到这里，让我们正式开始吧。

网络世界

你一定已经习惯了现在的网络生活，甚至可能会下意识地认为网络世界就应该是这个样子的：“一张平坦而且一望无际的巨大网络，每一台电脑就是网络上的一个节点，均匀地点缀在这张网上”。

这样的理解既对，又不对。从抽象的、虚拟的层面来看，网络世界确实是这样的，我们可以从一个节点无障碍地访问到另一个节点。

但现实世界的网络却远比这个抽象的模型要复杂得多。实际的互联网是由许许多多规模略小的网络连接而成的，这些“小网络”可能是只有几百台电脑的局域网，可能是有几万、几十万台电脑的广域网，可能是用电缆、光纤构成的固定网络，也可能是用基站、热点构成的移动网络……

互联网世界更像是由数不清的大小岛屿组成的“千岛之国”。

互联网的正式名称是Internet，里面存储着无穷无尽的信息资源，我们通常所说的“上网”实际上访问的只是互联网的一个子集“万维网”（World Wide Web），它基于HTTP协议，传输HTML等超文本资源，能力也就被限制在HTTP协议之内。

互联网上还有许多万维网之外的资源，例如常用的电子邮件、BT和Magnet点对点下载、FTP文件下载、SSH安全登录、各种即时通信服务等等，它们需要用各自的专有协议来访问。

不过由于HTTP协议非常灵活、易于扩展，而且“超文本”的表述能力很强，所以很多其他原本不属于HTTP的资源也可以“包装”成HTTP来访问，这就是我们为什么能够总看到各种“网页应用”——例如“微信网页版”“邮箱网页版”——的原因。

综合起来看，现在的互联网90%以上的部分都被万维网，也就是HTTP所覆盖，所以把互联网约等于万维网或HTTP应该也不算大错。

浏览器

上网就要用到浏览器，常见的浏览器有Google的Chrome、Mozilla的Firefox、Apple的Safari、Microsoft的IE和Edge，还有小众的Opera以及国内的各种“换壳”的“极速”“安全”浏览器。



那么你想过没有，所谓的“浏览器”到底是个什么东西呢？

浏览器的正式名字叫“Web Browser”，顾名思义，就是检索、查看互联网上网页资源的应用程序，名字里的Web，实际上指的就是“World Wide Web”，也就是万维网。

浏览器本质上是一个HTTP协议中的**请求方**，使用HTTP协议获取网络上的各种资源。当然，为了让我们更好地检索查看网页，它还集成了很多额外的功能。

例如，HTML排版引擎用来展示页面，JavaScript引擎用来实现动态化效果，甚至还有开发者工具用来调试网

页，以及五花八门的各种插件和扩展。

在HTTP协议里，浏览器的角色被称为“User Agent”即“用户代理”，意思是作为访问者的“代理”来发起HTTP请求。不过在不起混淆的情况下，我们通常都简单地称之为“客户端”。

Web服务器

刚才说的浏览器是HTTP里的请求方，那么在协议另一端的**应答方**（响应方）又是什么呢？

这个你一定也很熟悉，答案就是**服务器**，Web Server。

Web服务器是一个很大也很重要的概念，它是HTTP协议里响应请求的主体，通常也把控着绝大多数的网络资源，在网络世界里处于强势地位。

当我们谈到“Web服务器”时有两个层面的含义：硬件和软件。

硬件含义就是物理形式或“云”形式的机器，在大多数情况下它可能不是一台服务器，而是利用反向代理、负载均衡等技术组成的庞大集群。但从外界看来，它仍然表现为一台机器，但这个形象是“虚拟的”。

软件含义的Web服务器可能我们更为关心，它就是提供Web服务的应用程序，通常会运行在硬件含义的服务器上。它利用强大的硬件能力响应海量的客户端HTTP请求，处理磁盘上的网页、图片等静态文件，或者把请求转发给后面的Tomcat、Node.js等业务应用，返回动态的信息。

比起层出不穷的各种Web浏览器，Web服务器就要少很多了，一只手的手指头就可以数得过来。

Apache是老牌的服务器，到今天已经快25年了，功能相当完善，相关的资料很多，学习门槛低，是许多创业者建站的入门产品。

Nginx是Web服务器里的后起之秀，特点是高性能、高稳定，且易于扩展。自2004年推出后就不断蚕食Apache的市场份额，在高流量的网站里更是不二之选。

此外，还有Windows上的IIS、Java的Jetty/Tomcat等，因为性能不是很高，所以在互联网上应用得较少。

CDN

浏览器和服务是HTTP协议的两个端点，那么，在这两者之间还有别的什么东西吗？

当然有了。浏览器通常不会直接连到服务器，中间会经过“重重关卡”，其中的一个重要角色就叫做CDN。

CDN，全称是“Content Delivery Network”，翻译过来就是“内容分发网络”。它应用了HTTP协议里的缓存和代理技术，代替源站响应客户端的请求。

CDN有什么好处呢？

简单来说，它可以缓存源站的数据，让浏览器的请求不用“千里迢迢”地到达源站服务器，直接在“半路”就可以获取响应。如果CDN的调度算法很优秀，更可以找到离用户最近的节点，大幅度缩短响应时间。

打个比方，就好像唐僧西天取经，刚出长安城，就看到阿难与迦叶把佛祖的真经递过来了，是不是很省事？

CDN也是现在互联网中的一项重要基础设施，除了基本的网络加速外，还提供负载均衡、安全防护、边缘计算、跨运营商网络等功能，能够成倍地“放大”源站服务器的服务能力，很多云服务商都把CDN作为产品的一部分，我也会在后面用一讲的篇幅来专门讲解CDN。

爬虫

前面说到过浏览器，它是一种用户代理，代替我们访问互联网。

但HTTP协议并没有规定用户代理后面必须是“真正的人类”，它也完全可以是“机器人”，这些“机器人”的正式名称就叫做“爬虫”（Crawler），实际上是一种可以自动访问Web资源的应用程序。

“爬虫”这个名字非常形象，它们就像是一只只不知疲倦的、辛勤的蚂蚁，在无边无际的网络上爬来爬去，不停地在网站间奔走，搜集抓取各种信息。

据估计，互联网上至少有50%的流量都是由爬虫产生的，某些特定领域的比例还会更高，也就是说，如果你的网站今天的访问量是十万，那么里面至少有五六万是爬虫机器人，而不是真实的用户。

爬虫是怎么来的呢？

绝大多数是由各大搜索引擎“放”出来的，抓取网页存入庞大的数据库，再建立关键字索引，这样我们才能够搜索引擎中快速地搜索到互联网角落里的页面。

爬虫也有不好的一面，它会过度消耗网络资源，占用服务器和带宽，影响网站对真实数据的分析，甚至导致敏感信息泄漏。所以，又出现了“反爬虫”技术，通过各种手段来限制爬虫。其中一项就是“君子协定” robots.txt，约定哪些该爬，哪些不该爬。

无论是“爬虫”还是“反爬虫”，用到的基本技术都是两个，一个是HTTP，另一个就是HTML。

HTML/WebService/WAF

到现在我已经说完了图中右边的五大部分，而左边的HTML、WebService、WAF等由于与HTTP技术上实质关联不太大，所以就简略地介绍一下，不再过多展开。

HTML是HTTP协议传输的主要内容之一，它描述了超文本页面，用各种“标签”定义文字、图片等资源 and 排版布局，最终由浏览器“渲染”出可视化页面。

HTML目前有两个主要的标准，HTML4和HTML5。广义上的HTML通常是指HTML、JavaScript、CSS等前端技术的组合，能够实现比传统静态页面更丰富的动态页面。

接下来是**Web Service**，它的名字与Web Server很像，但却是一个完全不同的东西。

Web Service是一种由W3C定义的应用服务开发规范，使用client-server主从架构，通常使用WSDL定义服务接口，使用HTTP协议传输XML或SOAP消息，也就是说，它是一个**基于Web（HTTP）的服务架构技术**，既可以运行在内网，也可以在适当保护后运行在外网。

因为采用了HTTP协议传输数据，所以在Web Service架构里服务器和客户端可以采用不同的操作系统或编程语言开发。例如服务器端用Linux+Java，客户端用Windows+C#，具有跨平台跨语言的优点。

WAF是近几年比较“火”的一个词，意思是“网络应用防火墙”。与硬件“防火墙”类似，它是应用层面的“防火墙”，专门检测HTTP流量，是防护Web应用的安全技术。

WAF通常位于Web服务器之前，可以阻止如SQL注入、跨站脚本等攻击，目前应用较多的一个开源项目是ModSecurity，它能够完全集成进Apache或Nginx。

小结

今天我详细介绍了与HTTP有关系的各种应用技术，在这里简单小结一下要点。

1. 互联网上绝大部分资源都使用HTTP协议传输；
2. 浏览器是HTTP协议里的请求方，即User Agent；
3. 服务器是HTTP协议里的应答方，常用的有Apache和Nginx；
4. CDN位于浏览器和服务器之间，主要起到缓存加速的作用；
5. 爬虫是另一类User Agent，是自动访问网络资源的程序。

希望通过今天的讲解，你能够更好地理解这些概念，也利于后续的课程学习。

课下作业

1. 你觉得CDN在对待浏览器和爬虫时会有差异吗？为什么？
2. 你怎么理解WebService与Web Server这两个非常相似的词？

欢迎你通过留言分享答案，与我和其他同学一起讨论。如果你觉得有所收获，欢迎你把文章分享给你的朋友。



== 课外小贴士 ==

- 01 第一个网页浏览器也是蒂姆·伯纳斯-李发明的，名字就叫 WorldWideWeb。
- 02 第一个 Web 服务器由蒂姆·伯纳斯-李设计并参与开发，名字叫 CERN httpd。
- 03 Linux 上的 wget、curl 等命令行工具基于 http，所以也是一种 user agent。
- 04 Nginx 的正确发音应该是“engine eks”，不过我更愿意像 UNIX/Linux 那样称它为“engine ks”——虽然这是一个“错误”的发音，但却简洁明快。
- 05 你也许在浏览某些网站时遇到过要求“验证你不是机器人”的页面，这其实就是一种“反爬虫”手段。


透视 HTTP 协议

深入理解 HTTP 协议本质与应用

罗剑锋

奇虎360技术专家

Nginx/OpenResty 开源项目贡献者



新版升级：点击「🔔 请朋友读」，20位好友免费读，邀请订阅更有**现金**奖励。

精选留言：

● 不靠谱 ~ 2019-06-03 07:22:22

1.不是太清楚，个人认为不会区别对待，因为在正常程序应用来说，看不出是谁发起的请求。

2.web server是软件服务器，承载应用。

web service是一种服务方式。 [3赞]

作者回复2019-06-03 12:41:50

✓

● patsun 2019-06-03 01:01:56

1.CDN在对待浏览器和爬虫时没有差异，因为如果没有验证码或者其他验证方式区分的话，浏览器和爬虫都被视为User Agent（客户代理）

2.Websevice是服务，Web Server是服务器 [2赞]

作者回复2019-06-03 06:15:57

✓

● 磊爷 2019-06-03 12:53:51

1.正常情况下没有差异，客户端访问服务器，cdn加速缓存。

2.websevice是一种服务，提供相应的内容。

Web sever是服务器，可获得内容不受限。 [1赞]

作者回复2019-06-03 14:11:49

多补充一点，web server只能用http协议（因为是web），而websevice的接口就不固定了，有很多种。

● 壹笙 漂泊 2019-06-03 09:42:26

1、应该不会有差异，因为爬虫主要就是无限模仿浏览器行为

2、Web Server 是服务器，Web Service 是一种应用服务开发规范 [1赞]

作者回复2019-06-03 12:15:26

✓

- Amark 2019-06-03 09:39:05
老师，能不能通俗地讲讲RPC, SOAP, restful，之间的区别 [1赞]

作者回复2019-06-03 13:02:08

这个话题比较大。rpc就是把网络通信封装成了函数调用的形式，所以叫rpc。soap是web service的消息格式。RESTful是一种web服务接口的设计理念。

这三章都是与应用服务有关，但领域不同。

- 古夜 2019-06-03 09:20:57
tomcat不也是阿帕奇的吗？啥时候变成JAVA的了 [1赞]

作者回复2019-06-03 12:21:53

tomcat属于Apache基金会，用于Java开发，这里说的Apache是web服务器，可能我说的不清楚，让你误解了。

- -W.LI- 2019-06-03 08:44:07
第一个有差别，因为有爬虫技术
第二个:web server。web服务提供者，web服务器。web应用程序。web service。。。不知道了 [1赞]

作者回复2019-06-03 12:23:35

这个具体还要看cdn的策略，如果配置了反爬虫就会区别对待。

- 永钱 2019-06-03 07:58:51
老师把tomcat放在web服务器中比较，说速度慢，不公平呀 [1赞]

作者回复2019-06-03 12:16:29

抱歉啦，的确，tomcat应该是web容器。

- redrain 2019-06-03 07:35:57
有些网站全新上线的，没有外链，也没特意提交过，为什么也会有爬虫经过呢，入口在哪里 [1赞]

作者回复2019-06-03 12:57:30

这可能是从dns域名服务商那里获取了你的网站。

- Berry He 2019-06-03 02:26:10
第一个不太清楚，不敢妄加评论。
第二个:web server和web service是两个概念，前者是web服务器，像iis apache nginx这种。web service他只是一个或多个提供web请求响应的api，用来获取或提交更新web server资源的 [1赞]

作者回复2019-06-03 13:00:11

最后一句话不太准确，web service是应用服务，它的客户端不一定是web service。

- 瑞 2019-06-03 15:40:22
爬虫也是一种应用程序，自我启动应用程序去抓取网页数据吗

作者回复2019-06-03 16:47:43

是的。

- benying 2019-06-03 10:42:11
打卡

